



到底什么是偏见

≡ 分类

人生忠告

≡ 简述

克服前进道路上的所有障碍

≡ 声明

仅供学习交流使用，非商业使用，..

≡ 备注

Eliezer

Yudkowsky|www.readthesequences.com

<https://flowus.cn/preview/23b7c27f-07e9-437f-af92-ad6e9eb427d1>

偏见，是我们在追求真理过程中经常遇到的障碍之一。

它之所以成为障碍，正是因为我们的终极追求是真理。然而，并非所有障碍都能被称作偏见。

如果我们一上来就问“什么是偏见？”，实际上这种提问方式本身就颠倒了问题的顺序。就像俗语说的那样，“**疯狂有四十种形式，但理智只有一种。**”真理是一条狭长的小径，可命中的目标区域极小。

可能“她爱不爱我”听起来像个非此即彼的问题，但实际上，公式 $E = mc^2$ 在所有方程式的海洋里不过是一粒微尘，就像一张彩票在无数张彩票中幸运中奖一样。失败并非意外；相反，真正的成功因其难以预见而显得尤为珍贵，这本身就是一个值得探寻的谜题。

我们在一开始的时候，并不会因为偏见被看作是一件有害或不合时宜（Just Not Done）的坏事，就自然而然地承担着要“消除偏见”的道德责任。如果有人因为受到周围社会的影响而采取自以为理性的行动，他们可能会落入一个误区：认为自己应该机械地执行一些任务，却从未真正理解这些行为背后的深层原因。这种情况，正如我小时候读到的在 [《别闹了，费曼先生》](#) 一书中所描述的那样，不仅效果不佳，还带有误导性，而且考虑的并不周全。

（译者注："Just Not Done" 更多地被用来表达某种行为或举止在特定社会、文化环境中被认为是不恰当或不可接受的，通常指违反了未成文的社会规范或礼仪。这个表达方式强调了某些事情虽然没有明确的法律或规则禁止，但在社会习惯或礼节上是不被认可的。）

相反，无论出于什么原因，我们都想了解真相，却发现各种障碍阻碍我们获取真相。比如，它们可能源自于计算能力不足或信息获取成本高昂。有趣的是，许多障碍因为相似的特征而被归为一类，就像是在通往真相的障碍中形成了一个特定的聚集区域，我们称之为“偏见”。

“偏见是什么？”如果我们尝试从过往的经验中找出一系列具体的例子，来形成一个紧凑的定义或测试标准，可能是徒劳的。有时候，用一些具体的例子来说明，让听众自己去理解，可能比试图给出一个详尽的定义更有效。

比如，对于一个刚开始研究火的科学家来说，直接指向篝火说“那边橙色明亮的东西，就是火”，可能比使用复杂的定义如“火是物质燃烧时的化学反应，释放出热量和光”更为直观。同样，我们不应该因为无法精确定义某个概念就选择忽视它。我可能记不住广义相对论的具体方程式，但这并不妨碍我理解如果我走下悬崖，我会坠落这一自然法

则。对于偏见也是如此，即便我们不能简洁地界定它是什么，这并不意味着它对我们的影响就减少了。因此，我们可能会指出合取谬误（conjunction fallacies）、过度自信（overconfidence）、可用性启发式（availability heuristics）和代表性启发式（representativeness heuristics）、基本率忽略（base rate neglect）等概念，并简单地说：“就是这些东西。

（译者注：

1. 合取谬误（Conjunction fallacy）是一种逻辑错误，发生在人们错误地认为两个事件同时发生的概率比其中任何一个单独发生的概率都要高的情况。这种谬误通常在描述更具体、更详细的情况时出现，因为详细的情况听起来更具说服力，即使它们发生的概率实际上是更低的。
2. 可用性启发式（Availability heuristic）是一种心理学概念，指的是人们能够根据从记忆中易于调取的信息来评估事件发生的概率或频率的倾向
3. 代表性启发式（Representativeness heuristic）是一种认知心理学概念，指的是人们在评估一个对象属于某个

类别或在做出概率判断时，依赖于对象与某个类别的相似度或典型性。

4. 基本率忽视（Base rate neglect）是一个心理学和决策理论中的概念，指的是在判断或决策时，人们倾向于忽略或轻视整体频率（基本率）信息，而更多地依赖于特定情况或证据。这种倾向导致在评估概率时出现偏差，因为基本率是了解任何事件发生可能性的重要信息。）

话说回来，我们好像给所有阻碍我们认识真理的障碍贴上了“偏见”的标签，这些障碍并不是因为获取信息的成本或计算能力有限造成的。其实，很多时候，这些障碍源自我们自己心理机制的特定构造。

有时候，我们的思维方式就是为了反对准确认知而设计的，比如在政治辩论中为了胜出而采取的策略。或者，我们因为想要融入群体，就不自觉地去相信别人所相信的，这也是一种偏离真相的选择压力。有些情况下，我们的大脑就像是运行着某种算法，这可以帮助我们处理一些问题，但同时也会引发错误。

比如说，可用性启发式本身并没有什么不对，但它有时会让我们的做出一些错误判断。这些失误往往都是容易被发现并且能够简单描述的。当我们的的大脑做出一样的失误判断时，并且在经过仔细的实验检验或者深度思考（系统2）之后被指出来，我们就把这种失误称为“偏见”。这种认知失败，并不是因为我们的的大脑做得不够，而是因为我们的思维方式——即我们的“认知机器”的结构造成的。

“偏见”区别于那些源自我们所持信念或道德责任的错误。当我们意识到某个观点或行为与自己的信仰或道德标准不符时，我们称之为“错误”，而不是“偏见”。这类错误一旦被我们察觉，通常更容易被纠正。值得注意的是，尽管这些错误的深层原因可能仍旧是某种偏见。

相比之下，“偏见”并非由个人大脑损伤或特定文化习俗所导致的错误。它们根植于所有人类共有的心理机制中。

柏拉图被认为有偏见，并不是因为他不了解广义相对论（General Relativity）——在他的时代，这样的知识根本无法获得，所以他的无知并不能归咎于他的心理机制。

然而，如果柏拉图坚定地认为哲学家会成为更好的统治者，仅仅因为他自己是哲学家，这种信念如果是基于一种

广泛存在的、为了个人利益而形成的政治本能，而不是因为他被教导说每个人都有道德义务把自己分内的工作做到最好，或者是由于他童年时期的某些误解，那么这种信念就构成了偏见，不管是否有人指出过这一点给柏拉图。

纠正这种偏见可能需要付出高昂的代价，有时甚至可能无法纠正。但是，当我们深入剖析这种心理机制，识别出某些错误背后存在的可追溯的因果关系；当这些问题看起来更多是由于我们思维模式的进化而非仅仅因为信息缺失或错误信息所导致时；我们便将其定义为偏见。

个人而言，我认为我们的目标应该是培养个人的理性技能，以及提高我们探索真理的能力。我们所面临的挑战，在于要积极地实现对真理的追求，而不仅仅是避免失败。

错误的可能性是广泛的，形式多样，而这些错误构成了一个难以完全描述的广阔空间。正如同“对于某个苹果而言是这样，对于另一个苹果可能就不是这样”所示，对一个具体事物的理解可能远比试图概括所有事物的理解来得深刻。成功的路径相对狭窄，因此我们能够更具体、更精确地讨论它。

尽管我不反对讨论定义——正如你所见，但我们必须记住，这不是我们的主要目标。我们之所以聚在这里，是因为人类对于真理有一种伟大的追求，这源于我们对知识的渴望和好奇心。因此，让我们一起努力，克服前进道路上的所有障碍，不论我们是否将其称作“偏见”。