



我们所说的理性到底是什么

≡ 分类

人生忠告

≡ 简述

如果你过于频繁地谈论“道”，你可能永远也达不到它

≡ 声明

仅供学习交流使用，非商业使用，..

≡ 备注

Eliezer

Yudkowsky|www.readthesequences.com

<https://flowus.cn/preview/d20a2745-b67c-4cec-bca0-2ed6d37920d0>

我的意思是：

1. **认识理性 (Epistemic rationality):** 系统地提高信念的准确性。
2. **工具理性 (Instrumental rationality):** 系统地实现你的价值观。

当你睁开眼睛并环顾四周，你会根据桌子的位置找到你的笔记本电脑，根据墙壁来确定书柜的位置。如果你的视力或大脑有问题，你可能会误以为某个地方有书柜，但当你走过去拿书时，才意识到其实那里并没有书柜。

这就像是你持有一个错误的信念，并且拿着一张与实际领土不符的世界地图。而认识理性就是要构建一张精确的地图。信念与现实之间的这种一致性通常被称为“真理” ([truth](#))，我也乐于将其称为真理。

另一方面，工具理性关注的是如何实践，如何将未来引导至你所期望的方向。这是一种选择行动的艺术，以实现更符合你偏好的结果。我有时也把这称作“成功”（winning）。

因此，理性涉及形成准确的信念并作出有成效的决定。

这里的追求“真理”并不意味着忽略不确定性或者只关注直接证据。

从本质上讲，观察你周围的房间并在心里构建地图，与相信地球有一个熔融的核心或者朱利叶斯·凯撒是秃顶的，其实并没有本质区别。

这些问题在空间和时间上都与你相距甚远，可能看起来比关于你家书柜的问题更为抽象和模糊。然而，无论是关于2015年地球核心的状态，还是关于公元前50年凯撒是否秃顶的情况，背后都有其事实依据。这些事实可能会对你产生实质性的影响，哪怕你永远没有机会亲眼见到凯撒或触摸到地球的核心。

而且，追求“成功”并不意味着必须以牺牲他人为代价。人生规划可以是以合作和自我奉献为核心，而不仅仅是竞争。在这里，所说的“你的价值观”（Your values）涵盖了

你所关心的一切事物，包括对他人的关心。这并不局限于自私或狭隘的价值观。

当人们声称某人是理性的时候，这通常只是一种更加强烈的说法，意在表达“我认为某人是正确的”或“我认为某人是好的”。那么，我们为何还需要一个额外的词汇“理性”来描述“正确”(true) 和“好”(good) 呢？

我们也可以用类似的逻辑来质疑“真实”(true) 这个词。当我们在描述“雪是白色的”时候，没必要还特意加上“这是真的”，因为说“雪是白色的”已经隐含了这一点。

真理这一概念的价值在于，它允许我们更准确地预测和解释实验或现实世界中的现象。如果没有“真实”(true) 或“精准”(accurate) 这类概念的支撑，我们很难得出那些实用的、普遍适用的观点或总结。

“理性人总是做出能最大化期望收益的决定”这句话基于所谓的“工具理性”。然而，说“吃蔬菜是理性的”大概也可以用“吃蔬菜有好处”或“吃蔬菜对你有益”来替代。

我们需要像“理性”这样的词，以便更好地了解哪些思考方式能更有效地帮我们找到真理或价值，以及在哪些方面我们还不够好。

有时，实验心理学家会发现人们的推理方式很奇怪。例如，有些人认为“比尔是爵士乐手”的可能性要低于“比尔既是会计又是爵士乐手”的可能性，这似乎说不通。因为如果比尔既是会计又能演奏爵士乐，那么他显然也符合是爵士乐手的条件。关键在于，我们应该如何正确指出这种判断的错误呢？

实验心理学家会使用这两个黄金标准：概率论和决策理论。

概率论是我们进行理性思考的黄金规则。不论是确定书架的具体位置、计算地球核心的温度，还是估算凯撒大帝头上的头发数量，概率论都以公平且不偏不倚的方式处理这些问题。

它们本质上都是同一个问题：**如何处理证据和观察，以此来修正（或“更新”）我们的个人信念。**同样地，决策理论是指导理性行动的法则，无论我们的目标是什么，可选的行动方案如何，它的适用性都是一样的。

用“ $P(\text{某事件})$ ”来表示“某某事件发生的概率”，而 $P(A, B)$ 则用来表示“A事件和B事件同时发生的概率”。根据概率论的基本原理，我们得知 $P(A) \geq P(A, B)$ 。

因此，认为 $P(\text{比尔演奏爵士乐})$ 的概率小于 $P(\text{比尔演奏爵士乐, 比尔是会计师})$ 的概率，这种判断是错误的。

为了保持讨论的技术性，我们可以将这种概率判断称为非贝叶斯的。在数学上，那些符合明确定义原则的信念和行为，被称为“贝叶斯”(Bayesian) 的。

(译者注：贝叶斯理论 (Bayesian) 是一种统计学方法，用于在给定证据的情况下估计一个事件的概率。该理论依赖于对先验知识和新证据的结合，以更新对某一假设概率的认识。)

现代理性的概念并非仅限于文字推理。就像我之前提到的，你睁开眼睛，环顾四周，然后在脑海中构建一个房间的模型，这个房间里靠墙放着一个书架。这种理性概念足够广泛，它包括了你的眼睛和大脑的视觉区域，作为映射世界的工具。

同样，它也涵盖了你那无需言语的直觉。数学并不在乎我们是否用同一个英文词汇“理性”来指代斯波克或贝叶斯主义。数学模型关注的是实现目标或是描绘世界的有效方法，而不是这些方法是否符合我们对“理性”应有的预设概念和固有成见。

这样的解释并没有彻底澄清实际应用中“理性”所承载的意义，究其原因，主要有两点：

首先得说，对于现实世界中的大多数问题，想要完整应用贝叶斯理论在计算上几乎是不可能的。没人能做到精确无误地完成所有的数学运算，这就像你不可能通过计算夸克的活动来准确预测股市的走势一样。

要想在现实世界中发现真理并创造价值，光靠遵循数学公式是远远不够的，这需要更深层次的思考和更高超的技巧。

探寻真理和创造价值的过程，实际上是一门艺术，它要求我们认识到自身的局限，克服偏见，避免自我欺骗，保持情绪稳定，以便直面真相并采取必要行动，如此等等。

其次，有时连数学的应用本身也会遭到质疑。拿概率论和决策理论来说，这些数学工具旨在帮助我们理解世界和做出选择。但在某些场合下，人们会对这些工具是否真的适用产生疑问。

在概率论中，有一些问题涉及到观察者数量不确定的情况，这使得概率的计算变得格外复杂。

而在决策理论中，问题则涉及到其他智能体能够预测你的决策，这也引发了对决策理论的质疑。在这种情况下，试图通过重新定义“理性”一词来解决问题是不起作用的。因为这样做最终只会引出另一个问题：为什么别人必须接受这一新的定义呢？

我之所以对概率论不感兴趣，并不是因为它被视为来自拉普拉斯传下的神圣真理。相反，我对贝叶斯式的信念更新——也就是采用奥卡姆剃刀原则——感到着迷，是因为我相信这种思考方式能帮我们更系统、更具有“准确性”，即能更好地反映出世界实际情况的地图。

然后，还有一些思考方式的问题，似乎既不属于概率论也不属于决策论的范畴——比如，一旦你掌握了真相，应该怎样看待这个真相。在这里，再次尝试以特定的方式定义“理性”，并不能提供答案，反而只是预设了一个答案。

我在这儿，不是来跟你争论什么词语的意思，哪怕这个词是“理性”。我们用字母串连起来的意义，形成词汇，其实质是为了促进人与人之间的沟通，目的在于把一个人脑海中的想法，传达给另一个人。通过控制某个词与某个概念之间的联系，你既不能改变现实，也无法证明某个想法的正确与否。

因此，如果你能理解我通常所指的“理性”及其下属概念“认识理性”和“工具理性”的含义，那么我们的沟通就算是成功了：我们已经围绕如何定义“理性”进行了讨论，这正是我们需要探讨的全部内容。

剩下来讨论不是去纠结于“ra-tio-na-li-ty”（理性）这几个音节应该承载什么具体含义，而是要讨论什么样的思考方式才算是好的。

如果你说：“我相信X是（认识上的）理性的，但实际上Y是”，这样的话，你对“理性”这个词的使用可能与我所理解的含义不同。（比如，我认为“理性”应当在反思时保持一致——无论是“理性地”审视证据，还是“理性地”思考你如何处理这些证据，都不应该得出截然不同的结论。）

同样，如果你发现自己在说：“对我来说，从工具理性的角度，X是理性的选择，但我认为正确的做法是Y”，那么几乎可以肯定，你对“理性”或“正确”这两个词的理解与我不同。我使用“理性”一词时，旨在从规范性的角度挑选出理想的思维模式。

在这种情况下，或者在任何人们对词义存在分歧的情况下，你应该用更具体的语言来替代“理性”，比如说：“自

私的做法是逃跑，但我希望你至少能尝试一下把孩子从铁轨上救下来”，或者说“按照因果决策理论的常规表述，面对纽康问题时，你应该选择两个盒子，但我更愿意选择100万美元。”这样做能更清楚地表达你的观点，避免了不必要的词义纷争。

（译者注：因果决策理论（Causal decision theory）是一种决策理论，它主张个体在做决策时应该基于其行为可能导致的后果来选择行动。换句话说，它强调考虑因果关系，即一个行动如何会影响结果，来做出最有利的选择。

纽康问题（[Newcomb's Problem](#)）是一个著名的思想实验，用于探讨预测、自由意志和因果关系在决策中的作用。

问题的基本设定是这样的：有两个盒子，A和B。盒子A是透明的，里面有1000美元；盒子B是不透明的，里面可能有1百万美元，也可能什么都没有。一个超能力者已经预测了你会如何选择。如果预测你只选择盒子B，那么盒子B里就有1百万美元；如果预测你选择两个盒子，盒子B就为空。现在你需要做出选择：只选择盒子B，或者两个盒子都选择。

实际上，我建议你重读这篇文章，把所有“理性”一词替换成“foozal”（译者注：这个“foozal”是作者编造的词），看看这样是否改变了文章想要传达的含义。如果真的有所变化，那么我的建议就是：不要追求理性，而应该追求foozality（foozal性）。

“理性”这个词在很多场合下都能准确表达我的想法，特别是那些不那么极端的情形，而“非理性”也是如此。因此，在这些情况下，我不会对使用这些词感到忌讳。

然而，我们应该小心不要过度使用这个词。光是大声念叨，并不能为我们带来任何好处。如果你过于频繁地谈论“道”，你可能永远也达不到它。