

约束理论（上）

≡ 标签

高效工作

≡ 简述

提升任何系统效率的核心原则

≡ 声明

仅供学习交流使用，非商业使用，..

≡ 备注

Tiago Forte|fortelabs.com

<https://flowus.cn/preview/7c4613f7-46da-4378-90b7-898401cba9fd>

1. 将流程管理原则应用于知识型工作

约束理论（Theory of Constraints），我见过的最强大的行动框架。

这个理论，简称 TOC，提供了一套能提升任何系统效率的原则。不管是生产线、石油管道、数据中心还是人体，

统统适用。


但是，这个起源于 20 世纪 70 年代的 TOC 理论，在今天这个数字化的世界里几乎被遗忘了。我们忘记了工业和制造业几十年的经验教训，注定要重蹈覆辙。

我的目标是向新一代重新介绍 TOC，并展示它不仅适用于过去的工业，也同样适用于我们这个快节奏、互联网驱动、数字化的世界。

埃利亚胡·戈德拉特在他的 1984 年畅销书《目标》(*The Goal*) 中阐述了约束理论。这本书很特别——一部“商业小说”，讲述了一个后工业化中西部工厂经理与工厂斗争的故事。

30 年来，读者在这个故事中看到了自己的影子。《目标》成了过去几十年最畅销的非小说类书籍之一，人们将它的经验应用到了医学、军事、软件开发和建筑布局等多个领域。

TOC（约束理论）从一个简单的原则出发：每个系统都存在一个比其他所有瓶颈都更“紧”的瓶颈，我们称之为“约束”(constraint)。



对于某些系统，你一眼就能看出来：汽车总是在高速公路的同一段减速；办公室里那个所有人都要经过的门口；你总是疏通不了的那一段管道。

对于其他类型的系统，就不那么明显了。将概念从瓶颈扩展到任何类型的约束会有所帮助。

是什么限制了咖啡店服务更多顾客？可能是卡布奇诺的制作速度，信用卡审批的速度，或者是在那个时间地点以那个价格想喝咖啡的人数。如果足够受欢迎，约束甚至可能是门的宽度！

实际上，我们并不总是容易判断约束在哪里。但我们知道它一定潜伏在某处，否则咖啡店就可以以无限速度服务无


限数量的顾客。

是什么限制了人体——比如尤塞恩·博尔特的身体——跑得更快？可能是他的身体代谢葡萄糖或为肌肉供氧的能力；或者是他的鞋子在跑道表面的抓地力；或者是他内心深处某个限制性信念，阻止他全力以赴。

显然，一旦我们进入抽象、心理和非物质的世界，找到约束就变得更加困难。但我们有点超前了。

TOC 的第二个原则是，系统整体的性能受限于其最紧瓶颈的输出。

换句话说，如果管道中的水被一个狭窄的部分减慢到涓涓细流，那么管道末端的流出量就不可能超过涓涓细流。这一点更难直观地看出来，因为它被我们通常接触的系统的混乱所掩盖。




如果咖啡店的瓶颈是收银机的速度，那么它就不可能比收银机的速度快一丝一毫地服务顾客。如果尤塞恩·博尔特的瓶颈是他的快肌纤维的比例，那么他就不可能在不增加它们的情况下缩短一微秒的时间。

换句话说，任何系统的整体能力都受限于其最紧瓶颈的能力，或者更广泛地说，其最限制性约束的能力。

第三个原则源于前两个原则，但却是最深刻也最难以接受的。

这是 TOC 的红色药丸：如果第一和第二个原则成立，那么提高系统整体性能的唯一方法就是提高其瓶颈的能力（或更广泛地说，其约束的性能）。



以咖啡店为例，如果最限制性的约束是收银机，那么除了提高收银机速度之外，字面意义上的任何其他事情都不会对最终结果产生影响。不是更好的客户服务，不是更高质量的食物，不是更好的室内装饰，不是更快的 WiFi 或更干净的洗手间或更浓的咖啡或其他一百万个想法中的任何一个。

任何不针对“约束”的改进都是一种错觉，就像一条链条，只有加强最薄弱的环节，才能真正提升整体强度。

现在想想一家典型公司是如何运作的。

CEO 宣布“是时候提高公司业绩了！每个人都必须尽自己的一份力！”这个命令被传达到各个级别，每个经理都向

他的团队强调他们个人努力的重要性。

每个人都听到他们想听的：会计人员理解他们必须提高他们所保存的账簿的实用性（每个人对“实用性”的解释都不同）。软件开发人员点头同意更好的代码至关重要（每个人对“更好”的解释都不同）。营销人员一致认为更有创意的促销活动是唯一的解决方案（没有人费心去定义“创意”）。

每个人根据他们认为最自然、最理想或最容易理解的指标来解释 CEO 的指示。他们每个人都踏上了自己的个人使命，埋头苦干，却没有意识到他们的集体努力暗示了一种管理哲学：

“到处进行的局部改进会自动转化为整个组织的整体提升。”

约翰·梅纳德·凯恩斯曾说过：“那些自认为不受任何理论影响的实用主义者，往往只是某位已故经济学家的信徒。”

如果这种隐含的管理哲学是完全错误的呢？如果我们坚信可以通过分别优化每个部分来提升整个系统，而实际上，这种理念早已过时几十年，我们是否正按照一个失效已久的经济范式生活和工作？

这正是约束理论所提出的，也是它接下来要解决的问题。

2. 局部最优幻觉

前面，我提到了很多人不自觉地遵循了一种过时的管理理念：通过单独提升系统（比如公司）各个部分的表现，就能提高整个系统的整体表现。

这种孤立的提升被称为“局部最优”。局部最优是指对单个部分最有利的状态，而全局最优则是对整个系统最有利的状态。

换个说法来总结我们之前的结论：**局部最优的叠加，并不会自动带来全局最优。实际上，它可能会导致完全相反的结果。**


这可能是复杂系统最让人难以理解的一面：单独优化每个部分的表现，反而会导致整个系统严重优化不足。你越是“改进”系统的每个部分，整体表现反而越差。

让我们看看这种情况在公司中是如何体现的。

想象一下，公司里的每个部门都是一段管道，工作（比如报告、文件、图表、幻灯片、电子邮件和决策）从左向右


流程。每个圆圈代表某个部门的个体能力。

现在假设工程部门是组织的瓶颈，员工最少，因此能力最小：



© fortelabs.com

销售部门完成了一笔交易，然后交给产品部门。产品部门确定了项目范围，然后交给设计部门制作线框图。设计部门把他们的工作发给工程部门进行实际构建。每个人都觉得自己很有效率，很开心。



© fortelabs.com

但这就是事情开始变得有趣的地方。工程部门的能力很快就被填满了，这意味着再给他们发送更多的工作，也不会产生更多的成品。

但与此同时，销售、产品和设计部门该怎么办呢？他们不能就这么等着。他们遵循现代工作场所的普遍规则：“保持忙碌”。没有什么比“资源未充分利用”更让经理感到恐慌的了。同样，没有什么比感觉可能没有足够的工作来证明自己的雇佣价值更让员工感到恐慌的了。


所以他们怎么做？他们寻找新的客户来推销、新的产品来开发、新的设计来改进。我们总能找到要做的事情。

这可能看起来不是问题。实际上，这听起来可能像是我在描述一个高效运转的组织，里面充满了负责任、勤奋的人，看不到一个懒惰的人。

但这里有一个更深层的原则在起作用。如果我们应用之前讨论的原则，很快就会发现我们发现了一些局部最优。

“保持忙碌”的规则实际上是在优化每个部门的个体表现。


如果各个部门完全独立工作，这不会是个问题，但事实并非如此。随着销售、产品和设计部门不断开始新项目，更多的工作不可避免地流向已经负担过重的工程部门：



即使工程部门有纪律和权力拒绝所有新的需求，仅仅是应对传来的沟通也会占用他们宝贵的能力。处理更多的电子

邮件、提供更多的估算，以及进行必要的办公室政治来抵御来自业务其他部分的压力，都需要时间和精力。

结果是，瓶颈部门本已紧张的生产能力进一步降低：




随着瓶颈的能力下降，更多的工作堆积在它前面，这使得上游部门有更少的事情可做，这导致他们开始更多的项目，这又向瓶颈输送更多的工作，从而进一步降低了生产率。


生产力几乎降到零，而冲突、指责和避免责备的办公室政治则失控地螺旋式上升。但这还不是全部。

下游部门也发生着同样的情况：他们发现自己在等待瓶颈部门的工作，为了同时填满自己的能力，他们也开始新的

项目。再一次，这些部门正在最大化利用自己的能力：




至少这种下游活动不会影响瓶颈，对吧？错了。这些新项目也会为瓶颈创造更多工作，比如“需要工程部门参与”的决策。更多的电话、更多的电子邮件和更多的会议 - 瓶颈部门的生产能力进一步降低：



此时，产出大幅下降，所有人都对瓶颈感到愤怒，瓶颈也对所有人心生怨怼，而由于产品无法交付，公司的业绩受到严重影响。就在这种情况下，管理层感到必须介入。

由于他们不理解其中的原理，他们开始施加压力。每个人都需要加班、周末工作、在办公桌前吃午餐，并达到他们的目标！换句话说，变得更加忙碌！

由于真正影响整体产出的只有瓶颈的产能，其他环节的忙碌反而加剧了问题。各个部门不断向瓶颈施加更多工作压力，瓶颈则因不堪重负而更加强烈地反抗，结果其他人只能另起炉灶，开始新的任务……



这就是为什么一个每个人都 100%忙碌的公司效率极低。唯一可能让每个人都“保持忙碌”的方法是让每个人都最大化自己的生产力。而这种个体优化总是以牺牲公司整体利益为代价的。

试图改善组织的所有部分是一个值得追求的目标，但只有在瓶颈处的改进才能真正产生影响。

3. 流程的四大黄金法则

前面讲到，许多公司过度追求局部最优，导致员工超负荷工作、身心俱疲，同时整体产出下降，利润受损。

在探讨约束理论（TOC）提出的解决方案之前，我们需要先简要回顾一下“流程”（flow）的发展历史，而这一切要从亨利·福特说起。


如今，人们提起福特，大多会想到T型车和他的名言警句，但他真正的贡献在于发现了“流程”的四大基本原则：

1. **优化流程**：运营的首要目标是提升流程（即吞吐量，也就是在一定时间内生产流程能够完成的单位数量）。
2. **控制非生产活动**：提升流程的关键在于建立一个有效的机制，确保在不需要生产时避免过度生产。
3. **摒弃局部最优**：必须摒弃局部效率最大化的做法（如今更常被称为“局部最优”）。
4. **聚焦改进**：改进应遵循聚焦原则，优先优化对整体影响最大的位置，并随时调整方向，以确保资源发挥最大效益。

The Fundamental Principles of Flow



#1 | Optimizing Flow



#2 | Non-Production



#3 | Abolishing Local Optima



#4 | Focusing Process

© fortelabs.com

随着福特的生产线和装配线横扫全球，以前所未有的效率颠覆一个又一个行业，人们普遍认为，只有大规模生产一模一样的产品，才能证明整条生产线的价值。

大家都这么想，除了一个叫大野耐一的日本工程师。

大野意识到，流程原则是普适的——它们可以应用在许多不同的情况。

福特系统的巧妙之处，不仅在于其速度和一致性，更在于它以创新的方式限制了在制品库存。所谓在制品库存，简称 WIP，指的是那些已经部分加工但还没完成的零件，意味着它们还不能从生产线上撤下来。

这听起来可能没啥大不了，但现代制造业的一个重大发现是，WIP 是流程的最大敌人之一。如果不加以控制，WIP 往往会在工厂车间里堆积如山，弄得工厂乱七八糟，引发事故和错误，还普遍干扰那些能产出高质量产品的活动。

福特的系统通过用传送带连接每个工作中心，并严格限制它们之间的空间，确保了在制品根本不可能堆积。上游工作中心实际上无法比下游工作中心生产得更快，因为它们实际上是由一条传送带连接在一起的。

大野看到了福特的高明，但他也面临着一个非常不同的情况：日本汽车市场需要的是各种车型的小批量生产，而不是像美国市场那样大量生产一模一样的 T 型车。他负担不起把所有设备都用于单一车型的大规模生产。他需要的是有限数量的机器能够快速转向由不同零件组成的不同类型的车辆。

这就是大多数日本汽车制造商停止探索的原因——“这根本行不通！”

但大野意识到他可以通过不同的方式实现同样的目标——限制在制品。他发现他可以简单地制定一个规则，限制任何两个工作中心之间允许积累的 WIP 数量。

基于这一认识，他设计了看板系统。他没想到他的简单发明最终会成为更广泛的生产系统的一部分，这个系统最终会比福特的系统对世界产生更大的影响——即准时制生产。

但我们说得太快了。大野的看板系统是怎么运作的呢？

每个装满零件的容器在流水线上移动时，都会带上一张小卡片（在日语中称为kanban），上面标明该容器应包含多少个零件。当容器被移到下一个工作站时，卡片会被送回，通知前一个工作站仅生产当前使用的零件数量——而且只能生产这个数量，不多也不少。

看板的威力在于告诉每个工人何时不生产。大野成功地将福特的第二条原则（不生产）转化到他自己的环境中，将约束机制从传送带改为卡片。

大野还面临另一个挑战：如何聚焦持续改进的过程（第四条原则）。

大野的困难在于，无法将他的设备完全用于一种车型，这使得几乎不可能找到危及流程的问题。生产过程中零件种类繁多、变化频繁，仅凭观察很难识别出缺陷。

他的绝妙解决方案是“岩石和水”系统。

他会逐步减少“批次大小”(任何给定时间正在加工的零件数量)，这就像是慢慢降低水位。只要流程不中断，操作参数就会继续慢慢收紧：零件之间的公差变小，规格变得更加严格，要求的质量水平更高。

最终，“下降的水位”会揭示潜伏在下面的“岩石”(流程的障碍)。当发现一个障碍时，就会使用特殊技术系统地找出、诊断并永久修复干扰的根本原因。大野开发的这套技术最终被称为丰田生产系统 (TPS)，后来被扩展为准时制生产（或更广泛地称为精益制造）的整体哲学。

“严格的操作参数”的另一个说法是“高质量”，这个系统产生的成品质量的提高很快让所有目睹者感到惊讶。简而言之，大野的发明开创了现代世界，使从汽车到肥皂，从电视到药品，再到你现在可能正在使用的精密制造设备成为可能。

4. 用时间控制在制品

准时制生产 (Just-in-Time) /精益生产 (Lean) 方法彻底改变了全球产品的生产方式。

但像任何系统一样，它并不完美。它只是更加基本原理的又一应用，适用于特定的时间和地点。甚至在发展过程中，它的缺陷也开始显现。

准时制/精益生产最大的问题在于，它要求内部（生产）环境和外部（市场）环境都保持稳定和可预测。

在内部，任何可能影响变异性的因素——高精度生产的大敌——都必须精确控制到小数点后多位。

这解释了精益生产的一个不为人知的秘密：实施和消除所有问题需要极长时间。当时丰田供应商支持中心建议每条生产线需要 9 个月（这还是相当乐观的估计）。实际上，在整个公司范围内实施该系统有时需要长达 10 年时间。

在外部环境中，对可预测性的要求自然更加棘手。尽管丰田的订单流相对稳定，但它仍然必须建立一种接收订单（和承诺交付）的模式，限制每月订单的变化。


大多数公司无法对供应商和客户强加如此有利的条件。最糟糕的是，这种不稳定性不是生产部门能够控制的。它源于产品营销和销售方式，而非生产方式。

正是在这种情况下，一位名叫埃利亚胡·戈德拉特（Eliyahu Goldratt）的默默无闻的以色列物理学家于 1984

年出版了他的著作《目标》。在某种程度上，戈德拉特扮演了与大野几十年前相同的角色，将流程的基本原理转化为一个全新的范式。

戈德拉特意识到，限制在制品最有效的方法不是物理限制（传送带和卡片），而是时间。他建议不是通过摆弄生产线、容器和零件来限制在制品，而是通过控制新的在制品释放到生产中的时间来限制。


The Evolution of Work-In-Process Limits



© fortelabs.com


让我们用一个类比来理解为什么这种方法如此革命性：想象一条繁忙的高速公路，我们试图最大化其流量。如果你凌晨 5 点起床，你可能是高速公路上的第一辆车。只有一

辆车的通行量，没有任何阻碍，你可以随心所欲地快速行驶。



一段时间内，随着每增加一辆车，通行量都会增加，因为所有车辆都可以以相同速度行驶，不会遇到任何障碍或相互减速。

throughput = 10 cars




© fortelabs.com

但这只能持续到一定程度。最终，不断增加的车辆数量会开始“相互作用”——它们将没有空间以想要的速度行驶，开始在彼此后面聚集。

通行量将达到峰值，然后开始下降。也许你在高速公路上开车时注意到过这个临界点——一分钟前所有车辆还均匀分布并以良好速度流动，突然间多了几辆车就打破了系统平衡，交通陷入停滞。

too many incoming cars = traffic jam




© fortelabs.com

我们的问题是，“允许多少辆车进入高速公路才能实现最佳交通流量？”

从上方看时答案显而易见：最佳交通流量等于瓶颈的容量。


peak traffic flow is equal to the capacity of the bottleneck



© fortelabs.com

换句话说，最佳车辆数量就是能够持续通过最窄、最慢路段的车辆数量。这可能看起来是可怕的浪费。两侧明显可见的空车道（“未使用的容量”）怎么办？用尽可能多的车辆填满每条车道不是更有效率吗？

然而，请记住我们从功能失调的公司中学到的教训？



你会记得红色表示公司里的每个人都超负荷工作。每个人向工程部门（该组织的瓶颈）发送的工作越多，工程师实际完成任何工作的时间就越少。他们生产的越少，其他人“同时”开始的新项目就越多，从而在一个永无止境的恶性循环中向瓶颈发送更多工作。

在这种情况下，管理层需要做什么来解决这个问题是显而易见的：保持过剩产能。与其让每个人因害怕受到责备而一直“保持忙碌”，不如不仅允许而且要求每个部门（工程部门除外）有意不使用全部生产带宽，保留一些备用。

怎么可能呢？怎么可能不充分利用每一分钟反而是你能做的最有生产力的事？因为只有通过抑制他们可能开始的一

切，其他部门才能保护工程部门及其稀缺的带宽。

需要明确的是，这需要很大的信任。这是一种相互依存的关系。市场、产品、运营和销售部门的一些人可能有很好的理由想尽可能保持忙碌。他们的声誉、自尊，甚至晋升和加薪可能取决于他们经理对他们个人贡献的看法。

然而，单个人永远无法完成像整个组织齐心协力、步调一致所能实现的那样多的工作。正如我们所看到的，你必须做出选择：要么在个人层面进行优化，要么在整个团队层面进行优化。你不能两者兼得，因为这两者会导致截然不同的决策和权衡。

不要让公司里的每个人都忙碌起来，也不要占用高速公路上每一段车道。真正重要的是瓶颈的产能，必须不惜一切代价保护它。

5. 鼓-缓冲-绳 (Drum-Buffer-Rope)

这一节我想跟大家介绍鼓-缓冲-绳 (Drum-Buffer-Rope)，这是埃利亚胡·戈德拉特提出的一个颠覆性的制造生产方

法。

要明白为什么鼓-缓冲-绳这么革命性，我们得看看它是如何提出利用时间机制来控制在制品数量并最大化系统流量的。

和任何流程系统一样，鼓-缓冲-绳试图回答的问题是：“我们如何操作这个系统以实现最大产出？”产出，你可能还记得，是指在特定时间内生产过程能生产出的单位数量。

戈德拉特的答案是利用三个基于时间的杠杆点来实现这一目标：


1. 瓶颈的处理速率
2. 战略性放置的缓冲区
3. “释放材料”的时机

瓶颈的处理速率是决定整个系统工作节奏的“鼓”(就像行进乐队中的鼓手帮助整个团队步调一致)。可以想象成一个检测零件何时通过瓶颈的仪表。

当一个零件完成瓶颈处理后，鼓会通过“绳”向生产线起点（管道最左端）发送消息，告诉它“释放”一个新的在制

品。

换句话说，绳是“拉动”新工作项进入管道的信号，*只有当*瓶颈处理完一个项目时才会发出（与大野耐一早期的看板卡扮演相同的角色）。




还有一个要素需要添加，那就是**缓冲区**。

缓冲区在很多系统中都是重要元素：细胞壁是抵御外部环境的缓冲；汽车的减震器是抵御路面颠簸的缓冲；你提前两小时到达机场是为了缓冲意外延误。任何需要保护免受环境中的不确定性、变化或干扰，同时仍与该环境互动的系统部分，都需要某种缓冲。

制造业中缓冲区的必要性变得显而易见，当我们记住整个系统的产能等于瓶颈的产能时。这意味着瓶颈处机器故障（或员工生病）的“成本”不仅仅是那个工作中心损失的时间，它是整个公司的损失时间。瓶颈处损失的每一分钟都必须算作整个系统损失的一分钟。

因此，瓶颈处绝不能因任何原因闲置。做到这点的唯一方法是，在瓶颈前积压大量的在制品，这样即使上游的流程暂时中断，它也总会有工作可做。


这正是缓冲区的目的：保护瓶颈免受上游工作流中的干扰，平衡变化并从队列中按照保持瓶颈忙碌所需的确切数量和节奏分配工作块。



我们迄今为止研究的流程原则暗示了一种管理哲学：任何公司都不应承担超过其瓶颈处理能力的工作量。管理层的工作是确定瓶颈的产能，填满它，然后在一个项目完成之前不允许开始新项目。

换句话说，**要让系统的一个部分（瓶颈）得到充分利用，其他每个部分都必须有剩余产能。**

这与大多数组织的运作方式如此直接矛盾，以至于戈德拉特将其描述为采用约束理论时最大的思维方式转变。



忽视这些原则的最终结果对许多组织来说都很熟悉。如果有人透露甚至暗示他们没有足够的工作，我们会找些事情让他们做。如果找不到任何事情，我们就让他们离开。

因此，当然没人会真正“无事可做”。任何可能出现的多余产能都会被掩盖，埋藏在忙碌的工作中，而这些工作会不断膨胀，占满所有可用时间。等到真正有价值的工作机会出现时，他们已经“忙得不可开交”。

看到员工没有时间，并得出结论一定是“缺乏产能”的结论，管理层又雇佣了更多人。然而，由于这些额外的人可能并不会增加瓶颈的产能，他们最终只能做一些“忙碌”的工作。

不允许人们有剩余产能的讽刺结果是，公司最终拥有比以往任何时候都多得多的剩余产能。

DBR 的力量在于它不纠结于复杂的图表，不需要全面监控，也不规定工作应该如何进行。相反，它专注于系统动力学 (*system dynamics*)，使用三个基于时间的杠杆点加上反馈循环来最大化整体流量而不是产能。

通过利用时间机制，戈德拉特释放了流程的力量，并允许其原则远远超越制造业的范畴 - 应用于基于项目的咨询、销售和营销、零售和医疗服务，最终应用于电信和软件开发。

在所有这些不同的领域，工作不是通过装配线的顺序线性流程，而是通过更加严格、更加线性的时间流程。

有了这一洞见，我们就可以开始将诞生于工业时代油腻工厂的想法应用到当今最前沿的知识工作中。